

INSTITUTO POLITÉCNICO NACIONAL  
ESCUELA SUPERIOR DE COMPUTO



Nombre de los alumnos: Sandoval Muñoz Emanuel, Valerio López José

Eduardo, Trejo Sierra Héctor.

Matriculas: 2022670104, 2022670002, 2021630065.

Maestr@: CAMACHO VAZQUEZ VANESSA ALEJANDRA

Materia: MACHINE LEARNING

Grupo: 6CV1

Trabajo: Práctica 8. Redes neuronales usando Python y Tensorflow

## Código completo de las redes neuronales

Red 1, esta red es la primera con la que se inicia, para poder hacer las otras 2 solicitadas

```
import tensorflow as tf
import numpy as np
import matplotlib.pyplot as plt

# Datos de entrenamiento
celsius = np.array([-40, -10, 0, 8, 15, 22, 38], dtype=float)
Fahrenheit = np.array([-40, 14, 32, 46, 59, 72, 100], dtype=float)

# Definición de la capa y el modelo
capa = tf.keras.layers.Dense(units=1, input_shape=[1])
modelo = tf.keras.Sequential([capa])

# Compilación del modelo
modelo.compile(
    optimizer=tf.keras.optimizers.Adam(0.1),
    loss='mean_squared_error'
)

# Entrenamiento del modelo
print("Comienza entrenamiento...")
historial = modelo.fit(celsius, Fahrenheit, epochs=1000, verbose=False)
print("Modelo entrenado")

# Visualización de la pérdida durante el entrenamiento
plt.xlabel("# Epoca")
plt.ylabel("Magnitud de pérdida")
plt.plot(historial.history['loss'])
plt.show()


# Predicción
print("Predicción")
resultado = modelo.predict(np.array([100.0]))
print("El resultado es: " + str(resultado[0][0]) + " Fahrenheit!")

# Variables internas
print("Variables internas")
print(capa.get_weights())
```

## Ejecución

```
Comienza entrenamiento...  
Modelo entrenado  
Predicción  
1/1 ————— 0s 39ms/step  
El resultado es: 211.74405 Fahrenheit!  
Variables internas  
[array([[1.7981333]], dtype=float32), array([31.930733], dtype=float32)]
```

## Grafica



## Red neuronal 1 convertir de grados Fahrenheit a Celsius

```
import tensorflow as tf
import numpy as np
import matplotlib.pyplot as plt

# Datos de entrenamiento
fahrenheit = np.array([-40, 14, 32, 46, 59, 72, 100], dtype=float)
celsius = np.array([-40, -10, 0, 8, 15, 22, 38], dtype=float)

# Definición de la capa y el modelo
capa = tf.keras.layers.Dense(units=1, input_shape=[1])
modelo = tf.keras.Sequential([capa])

# Compilación del modelo
modelo.compile(
    optimizer=tf.keras.optimizers.Adam(0.1),
    loss='mean_squared_error'
)

# Entrenamiento del modelo
print("Comienza entrenamiento...")
historial = modelo.fit(fahrenheit, celsius, epochs=1000, verbose=False)
print("Modelo entrenado")

# Visualización de la pérdida durante el entrenamiento
plt.xlabel("# Epoca")
plt.ylabel("Magnitud de pérdida")
plt.plot(historial.history['loss'])
plt.show()


# Predicción
print("Predicción")
resultado = modelo.predict(np.array([100.0]))
print("El resultado es: " + str(resultado[0][0]) + " Celsius!")

# Variables internas
print("Variables internas")
print(capa.get_weights())
```

## Ejecución

```
Comienza entrenamiento...  
Modelo entrenado  
Predicción  
1/1 ————— 0s 37ms/step  
El resultado es: 37.846046 Celsius!  
Variables internas  
[array([[0.55616736]]), dtype=float32), array([-17.770693], dtype=float32)]
```

## Grafica



## Red neuronal 2

```
import tensorflow as tf
import numpy as np
import matplotlib.pyplot as plt

# Datos de entrenamiento
fahrenheit = np.array([-40, 14, 32, 46, 59, 72, 100], dtype=float)
celsius = np.array([-40, -10, 0, 8, 15, 22, 38], dtype=float)

# Definición de la capa y el modelo
oculta1 = tf.keras.layers.Dense(units=3, input_shape=[1])
oculta2 = tf.keras.layers.Dense(units=3)
salida = tf.keras.layers.Dense(units=1)
modelo = tf.keras.Sequential([oculta1, oculta2, salida])

# Compilación del modelo
modelo.compile(
    optimizer=tf.keras.optimizers.Adam(0.1),
    loss='mean_squared_error'
)

# Entrenamiento del modelo
print("Comienza entrenamiento...")
historial = modelo.fit(fahrenheit, celsius, epochs=1000, verbose=False)
print("Modelo entrenado")

# Visualización de la pérdida durante el entrenamiento
plt.xlabel("# Epoca")
plt.ylabel("Magnitud de pérdida")
plt.plot(historial.history['loss'])
plt.show()


# Predicción
print("Predicción")
resultado = modelo.predict(np.array([100.0]))
print("El resultado es: " + str(resultado[0][0]) + " Celsius!")

# Variables internas
print("Variables internas")
print(oculta1.get_weights())
print(oculta2.get_weights())
print(salida.get_weights())
```

## Ejecución

```
Comienza entrenamiento...
Modelo entrenado
Predicción
1/1 ----- 0s 51ms/step
El resultado es: 37.8461 Celsius!
Variables internas
[array([[ -0.0600067,  0.45854184, -0.1032307 ]], dtype=float32), array([[-3.4929903, -3.3314588,  1.2664479], dtype=float32)]
[array([[ -0.58691114,  0.04480637, -0.8916987 ],
        [ -0.24449052, -0.59302366, -0.78185195],
        [ 0.83232725,  0.20785694,  0.00677548]], dtype=float32), array([0.86248815, 2.9356275, 3.3355174 ], dtype=float32)]
[array([[ -0.20345353],
        [ -0.6522517 ],
        [ -1.0792526 ]], dtype=float32), array([-3.743288], dtype=float32)]
```

## Grafica





## Tema: Aprendizaje Automático vs Programación Regular

Estos dos son 2 paradigmas distintos en el desarrollo del software, la programación regular implica escribir explícitamente cada paso que el programa debe seguir para resolver un problema.

En contraste el aprendizaje automático no requiere que el programador defina reglas explícitas. En lugar de esto el programador proporciona un conjunto de datos y el modelo de aprendizaje automático aprende a partir de estos datos. Utilizando algoritmos como redes neuronales, árboles de decisión o máquinas de soporte vectorial, el modelo identifica patrones en los datos que le permiten hacer predicciones o tomar decisiones. Este aprendizaje es especialmente útil para problemas donde definir reglas explícitas es complejo o inviable debido a la naturaleza variable y extensa de los datos.

Escenarios que resolvemos.

Supongamos que se está desarrollando un sistema para predecir el éxito académico de los estudiantes en una universidad basada en varios factores, el objetivo es identificar a los estudiantes que podrían necesitar apoyo adicional para mejorar su rendimiento y aumentar sus posibilidades de éxito.



En un escenario real, se requiere definir una serie de reglas y condiciones basadas en los factores, lo cual podría ser muy complejo y poco preciso debido a la cantidad de variables y su interacción, sin embargo con el aprendizaje automático, podemos entrenar un modelo con datos históricos de estudiantes y sus resultados académicos para que el sistema aprenda a predecir el éxito académico basado en los factores sin la necesidad de definir reglas explícitas.

(Conceptos a conocer,

- Datos de entrenamiento.
- Algoritmos de aprendizaje
- Función de pérdida
- Proceso de entrenamiento
- Validación y prueba
- Red Neuronal



Nombre:

Día

Mes

Año

Folio

Tema:

Proceso que sigue la Red neuronal.

Recopilación y procesamiento de datos: Recolectar datos relevantes y limpiarlos, normalizar y transformar los datos para que sean adecuados para el modelo.

Definición de la arquitectura de red: Decidir la cantidad de neuronas y capas.

Inicialización de pesos: Asignar valores iniciales aleatorios a los pesos de las conexiones entre neuronas.

Forward propagation: Pasar los datos de entrada a través de la red, hasta obtener una salida.

Cálculo de la pérdida: Comparar el valor de salida con el valor real.

Backward propagation: Calcular el gradiente.

Actualización de pesos: Ajustar los pesos utilizados utilizando un algoritmo de optimización.

Iteración del proceso: Repetir los pasos de propagación hacia adelante.



# Cambios en la implementación

La principal diferencia que se puede notar a la hora de implementar la red Neuronal Serial y la capacidad de la red para capturar y aprender patrones complejos en los datos.

Lo red serial en su primer capa binomial es fácil de entender pero para su correcta implementación con múltiples capas o tener una mayor capacidad de aprendizaje y precisión esto a costa de una mayor carga computacional y tiempo de entrenamiento.



Nombre:

Día

Mes

Año

Folio

Tema:

¿Cómo va a aprender?

Aprender a través del proceso, efectivo descrito anteriormente, los procesos ocurren en los siguientes pasos,

- Entrenamiento inicial,
- Evaluación de Error
- Representación
- Actualización de pesos
- Repetición